

NOTE DE SUIVI — SEMAINE 2

PROJET DATA — MJCC

Note de Suivi — Semaine 2 : Extraction SSIS

PassJeunes & Jam3iya.ma vers STAGING_MJCC | Stage Big Data 2025-2026

STATUT	Semaine 2 / 8	Phase : SSIS Extract + Staging	En cours
--------	---------------	--------------------------------	----------

Objet de ce document

Cette note presente les travaux realises durant la **Semaine 2** du projet : la mise en place du pipeline d'extraction **SSIS**, depuis les deux bases sources (**PassJeunesDB** sur SQL Server et **jam3iya_db** sur MySQL) vers la base tampon **STAGING_MJCC**. Ce document detaille les Connection Managers configures, la structure des Data Flow Tasks, la gestion des erreurs, et le planning de la Semaine 3 (Transform + Load).

1. RAPPEL — ETAT A LA FIN DE LA SEMAINE 1

La Semaine 1 a livré : les deux bases sources créées et peuplées (**PassJeunesDB** sur SQL Server, **jam3iya_db** sur MySQL), le schéma du Data Warehouse (**DWH_MJCC**) et de la base de staging (**STAGING_MJCC**), ainsi que les guides de configuration SSIS et SSAS. La Semaine 2 démarre donc avec des données déjà disponibles côté sources, prêtes à être extraites.

Element	Statut fin S1
PassJeunesDB (SQL Server)	5 tables créées et peuplées : Beneficiaire (10 000), Partenaire (200), Solde (~72 600), Operation (~398 700), Motatawi3 (~490)
jam3iya_db (MySQL)	6 tables créées et peuplées : maison_jeunes (60), association (500), personne_association (~15 600), colonie_vacances (40), activite (~2 250), rapport_activite (~1 170)
DWH_MJCC (SQL Server)	Schema en étoile créé (script schema_dwh_sqlserver.sql), vide pour l'instant
STAGING_MJCC (SQL Server)	Schema créé (script schema_staging.sql), tables stg_* vides, table etl_log prête

2. CONFIGURATION DES CONNECTION MANAGERS

Premiere etape de la Semaine 2 : creer le projet SSIS **ETL_MJCC** dans SQL Server Data Tools (SSDT), puis configurer les 4 Connection Managers necessaires pour relier les 2 sources, la base de staging et le Data Warehouse.



Les 4 Connection Managers configures dans le projet SSIS ETL_MJCC.


Detail des connexions

Connection Manager	Type	Cible	Point d'attention
CM_PassJeunes_Source	OLE DB	PassJeunesDB (SQL Server)	Authentification Windows ou SQL Server
CM_Jam3iya_MySQL	ODBC	jam3iya_db (MySQL)	Necessite le driver MySQL Connector/ODBC 8.0
CM_Staging	OLE DB	STAGING_MJCC (SQL Server)	Meme serveur que le DWH en general
CM_DWH	OLE DB	DWH_MJCC (SQL Server)	Utilise uniquement en Semaine 3 (Load)

A verifier avant de continuer : chaque Connection Manager doit passer le test "Test Connection" dans SSDT. Pour CM_Jam3iya_MySQL, creer d'abord un DSN systeme via ODBC Data Source Administrator (Windows) avant de le referencer dans SSIS.

3. DATA FLOW TASK — EXTRACTION VERS STAGING

Deux packages independants extraient chacun leur source respective vers **STAGING_MJCC** : **01_Extract_PassJeunes.dtsx** (source OLE DB) et **02_Extract_Jam3iya.dtsx** (source ODBC). Un Execute SQL Task de purge precede chaque extraction pour eviter les doublons.



Structure des Data Flow Tasks d'extraction, avec purge prealable via Execute SQL Task.


Tables extraites par package

Package	Tables sources	Tables de staging cibles
01_Extract_PassJeunes	Beneficiaire, Partenaire, Solde, Operation, Motatawi3	stg_passjeunes_beneficiaire, stg_passjeunes_partenaire, stg_passjeunes_solde, stg_passjeunes_operation, stg_passjeunes_motatawi3
02_Extract_Jam3iya	maison_jeunes, association, personne_association, colonie_vacances, activite, rapport_activite	stg_jam3iya_maison_jeunes, stg_jam3iya_association, stg_jam3iya_personne_association, stg_jam3iya_colonie_vacances, stg_jam3iya_activite, stg_jam3iya_rapport_activite

Note technique : les tables de staging (stg_*) reprennent la structure brute des sources, sans FK ni contraintes — elles servent uniquement de zone tampon avant nettoyage. Les vraies FK et surrogate keys seront resolues en Semaine 3 lors du chargement vers DWH_MJCC.

4. ORCHESTRATION — PACKAGE MAITRE

Le package **00_Master_ETL.dtsx** orchestre l'exécution séquentielle des packages d'extraction via des tâches Execute Package Task, avec gestion des erreurs et notification.



Control Flow du package maître : exécution séquentielle avec notification en cas de succès ou d'échec.

Gestion des erreurs et logs

Chaque Data Flow Task est encadré par une mise à jour de la table **etl_log** (STAGING_MJCC) : une ligne est insérée au début de l'exécution (statut = "En cours"), puis mise à jour à la fin avec le nombre de lignes traitées et le statut final ("Succès" ou "Echec"). Les lignes en erreur sur les composants Lookup/Destination sont redirigées vers un fichier plat (**errors_log.csv**) plutôt que de faire échouer tout le package.

5. LIVRABLES DE LA SEMAINE 2


Livrable	Description	Statut
Projet SSIS ETL_MJCC	Cree dans SQL Server Data Tools (SSDT)	Termine
4 Connection Managers	PassJeunes (OLE DB), Jam3iya (ODBC), Staging (OLE DB), DWH (OLE DB)	Termine
Package 01_Extract_PassJeunes	Data Flow Task : 5 tables source vers staging	Termine
Package 02_Extract_Jam3iya	Data Flow Task : 6 tables source vers staging	Termine
Package 00_Master_ETL	Orchestration + notification succes/echec	Termine
Table etl_log alimentee	Tracabilite de chaque execution (lignes, statut, duree)	Termine

Checklist de validation avant de passer a la Semaine 3

- Les 4 Connection Managers passent le test "Test Connection"
- Chaque Data Flow Task s'execute sans erreur sur un petit echantillon
- Les tables stg_* de STAGING_MJCC contiennent bien les donnees extraites
- Le nombre de lignes en staging correspond au nombre de lignes source (voir Row Count)
- La table etl_log s'alimente correctement a chaque execution
- Executer le pipeline 2 fois de suite ne cree pas de doublons dans le staging

6. PROCHAINE ETAPE — SEMAINE 3

La Semaine 3 enchaîne sur la **transformation et le chargement** : résolution des clés substituts via des Lookup Transformations en cascade (dim_region, dim_temps, dim_beneficiaire...), puis chargement final dans **DWH_MJCC**. Le pipeline sera ensuite planifié via **SQL Server Agent** pour une exécution quotidienne automatique.



Aperçu des taches de la Semaine 3

Tache	Detail
Lookup Transformations	Resolution des surrogate keys sur toutes les dimensions (dim_region, dim_temps, dim_beneficiaire, dim_association...)
Derived Column	Calculs derives : age, statut_pass, duree_adhesion
Chargement DWH_MJCC	Insertion dans les tables de faits et dimensions du DWH
Planification SQL Server Agent	Job quotidien pointant vers 00_Master_ETL.dtsx
Tests d'idempotence	Verifier qu'une double execution ne cree pas de doublons

Points a valider avec l'encadrant

1. Le rythme d'avancement (Extraction en S2, Transform/Load en S3) est-il adapte ?
2. Faut-il prévoir un chargement incremental (delta quotidien) des la Semaine 3, ou un chargement complet (full load) suffit-il pour la duree du stage ?
3. Disponibilite pour une demonstration rapide du pipeline d'extraction fonctionnel ?