

PROJET DATA — MJCC

Gestion & Visualisation des Donnees (Mise a Jour)

PassJeunes, Jam3iya.ma & Motatawi3 | Stage Big Data 2025-2026

Resume du Projet (mise a jour)

Ce document presente l'architecture et les composantes du projet data developpe dans le cadre d'un stage au Ministere de la Jeunesse, de la Culture et de la Communication (MJCC). Le projet centralise, traite et visualise les donnees de **PassJeunes**, **Jam3iya.ma** et du programme **Motatawi3**. Il repose sur un **Data Warehouse SQL Server**, un pipeline **SSIS** automatise, une couche analytique **SSAS Tabular**, des dashboards **Power BI**, des rapports PDF auto-generees et des modeles de **Machine Learning** predictifs.

3

Plateformes analysees

9

Tables sources

SSIS

Moteur ETL

SSAS

Couche analytique

8

Semaines de stage

1. CONTEXTE & OBJECTIFS DU PROJET

Le Ministère de la Jeunesse, de la Culture et de la Communication gere plusieurs plateformes numeriques majeures au Maroc. Ces plateformes generent chaque jour des donnees precieuses sur les comportements des jeunes, le volontariat et l'activite des associations. Cependant, ces donnees restent eparillees et difficiles a exploiter. Ce projet propose une solution data complete pour y remedier.

Les plateformes sources

Plateforme	Description	Base de donnees
PassJeunes (passjeunes.ma)	Application offrant des reductions aux jeunes (16-30 ans). Systeme de credit annuel (Solde) par partenaire. Desactivation automatique du Pass a 30 ans.	SQL Server
Jam3iya.ma	Gestion numerique des Maisons de Jeunes et des associations qui y sont conventionnees.	MySQL
Motatawi3.ma	Programme national de volontariat, 18-22 ans, inscription via l'application Pass Jeunes.	Rattache a PassJeunes


Note importante — Donnees simulees : Les donnees reelles ne peuvent pas etre utilisees dans ce projet de stage. Les donnees ont ete **simulees de maniere realiste** en Python (noms marocains authentiques, structures et distributions realistes) pour les 9 tables sources.

Objectifs du projet

#	Objectif	Resultat attendu
1	Centraliser les donnees	Un Data Warehouse SQL Server unique regroupant les 3 plateformes
2	Automatiser le traitement	Un pipeline SSIS planifie via SQL Server Agent, sans intervention humaine
3	Visualiser les indicateurs	Un modele SSAS Tabular alimentant des dashboards Power BI clairs
4	Generer des rapports	Des rapports PDF produits automatiquement (hebdo/mensuel)
5	Predire & analyser	Des modeles ML pour anticiper les activites et repartir les equipements

2. ARCHITECTURE GLOBALE DU SYSTEME

L'architecture suit un flux lineaire de data engineering, allant de l'**extraction des donnees brutes** jusqu'a la **consommation finale** par les utilisateurs. La stack technique repose entierement sur l'ecosysteme SQL Server (SSIS + SSAS), garantissant une integration native avec les sources et Power BI.



Architecture en pipeline : les donnees transitent des sources SQL Server/MySQL vers le Data Warehouse, puis sont exploitees par SSAS Tabular, Power BI, les modeles ML et les rapports PDF.


Que signifie chaque composant ?

Composant	Role simplifie	Analogie simple
Sources (SQL Server & MySQL)	Bases de donnees d'origine ou les donnees sont deja stockees par les plateformes.	Les entrepots de matieres premieres
SSIS (ETL)	Extraction, nettoyage et chargement automatique des donnees.	La chaine d'assemblage
Data Warehouse (SQL Server)	Base de donnees centrale, optimisee pour l'analyse et le reporting.	Le magasin central organise
SSAS Tabular	Modele analytique avec mesures DAX, source unique pour Power BI.	Le traducteur entre les donnees et les graphiques
Power BI	Interface graphique pour explorer les donnees visuellement.	Le tableau de bord d'un pilote d'avion
Modeles ML	Algorithmes qui apprennent des donnees pour faire des predictions.	Le conseiller strategique automatique

3. DATA WAREHOUSE — MODELISATION v2

Le Data Warehouse est le coeur du projet. Il regroupe toutes les donnees dans une structure optimisee pour l'analyse (SQL Server, schema en etoile). Le modele a ete **revise en profondeur (v2)** apres analyse des plateformes officielles du ministere.

Explication simple : Une "table de faits" contient les chiffres a analyser. Une "table de dimension" apporte le contexte. Ensemble, elles repondent a des questions comme : "Combien de beneficiaires de Rabat sont inscrits a Motatawi3 ?" ou "Quel budget les associations actives de Fes ont-elles consomme en 2024 ?"




Schema en etoile v2 : deux constellations (PassJeunes / Jam3iya) reliees par le CIN du beneficiaire.

Entites principales — modele v2

Entite	Description	Source
Beneficiaire	CIN, profil complet, nationalite, handicap, statut_pass (desactive automatiquement a 30 ans)	PassJeunes
Partenaire / Solde / Operation	Credit annuel par partenaire, decompote mensuel ou a l'usage	PassJeunes
Motatawi3	Volontariat 18-22 ans, code de suivi, statut du dossier	PassJeunes
Maison_Jeunes	Centres physiques accueillant associations et activites	Jam3iya.ma
Association	Finances integrees (recettes, subvention), formulaire d'adhesion	Jam3iya.ma
Personne_Association	Fusion Membre_Bureau + Animateur (type_personne, role)	Jam3iya.ma
Activite	Reguliere ou Saisonniere_Campus, liee a une Colonie_Vacances	Jam3iya.ma
Rapport_Activite	Texte + statistiques envoyes apres chaque activite	Jam3iya.ma

4. PIPELINE ETL — SSIS

L'ETL (Extract, Transform, Load) collecte les données des sources, les nettoie, puis les charge dans le Data Warehouse. Il est implémenté avec **SQL Server Integration Services (SSIS)**, planifié via **SQL Server Agent** pour une exécution quotidienne automatique.



Les 5 étapes du pipeline ETL, implémentées en packages SSIS.


Détail des 5 étapes

Etape	Nom	Ce qui se passe concrètement
1 - EXTRACT	Extraction	Connection Managers OLE DB (SQL Server) et ODBC (MySQL). Lecture des tables sources PassJeunesDB et jam3iya_db.
2 - STAGING	Copie brute	Chargement dans STAGING_MJCC (tables stg_*), avec Execute SQL Task de Truncate avant chaque cycle.
3 - TRANSFORM	Transformation	Lookup Transformation + Derived Column pour nettoyer et normaliser les données (regions, categories).
4 - ENRICH	Enrichissement	Résolution des clés substituts (surrogate keys) via Lookups en cascade sur les dimensions.
5 - LOAD	Chargement	Insertion dans DWH_MJCC (SQL Server). Mise à jour des tables de faits et dimensions.

Outils utilisés : SSIS (SQL Server Data Tools) | Connection Managers OLE DB/ODBC | Lookup / Derived Column / Conditional Split | SQL Server Agent (planification) | STAGING_MJCC (base tampon) | DWH_MJCC (SQL Server)

5. TABLEAUX DE BORD & VISUALISATION

Les tableaux de bord Power BI se connectent au modele **SSAS Tabular** en mode Connect Live : le modele SSAS reste la source unique de verite, sans duplication des donnees. Trois dashboards principaux sont prevus.



Aperçu des trois tableaux de bord Power BI, alimentés par les mesures DAX du modèle SSAS Tabular.

KPIs et indicateurs par dashboard

Dashboard	Indicateurs clés affichés
Dashboard 1 Vue Beneficiaires (PassJeunes)	- Evolution mensuelle des inscriptions - Repartition par region, genre, type_statut - Suivi des desactivations a 30 ans - Top categories d'operations (culture, sport, transport) - Inscrits Motatawi3 (18-22 ans) et statuts de dossier
Dashboard 2 Vue Associations (Jam3iya.ma)	- Nombre d'associations actives par region et maison de jeunes - Recettes, depenses, subventions par domaine d'activite - Repartition Personne_Association (Membre_Bureau vs Animateur) - Nombre d'activites (Regulieres vs Saisonnières_Campus) - Suivi des rapports d'activite
Dashboard 3 Vue Croisee	- % de beneficiaires egalement lies a une association (via CIN) - Repartition des equipements par maison de jeunes selon l'activite - Comparatif regional (12 regions) - Correlation activite Pass et densite associative

6. MODELES D'INTELLIGENCE ARTIFICIELLE (MACHINE LEARNING)

Le module de Machine Learning reste implemente en **Python (Scikit-learn / XGBoost)**, hors ecosysteme SQL Server, et se connecte directement au Data Warehouse pour l'entrainement. Les cas d'usage ont ete adaptes au modele v2 : desactivation a 30 ans (regle deterministe, pas de churn a predire), et un nouveau modele de **repartition des equipements** par maison de jeunes selon l'activite des associations qui l'utilisent.

C'est quoi le Machine Learning ? Un algorithme qui, apres avoir observe l'historique des activites, est capable de predire combien d'activites vont avoir lieu le mois prochain — comme un meteorologue qui predit la pluie en analysant les donnees climatiques.

Figure 5 — Cas d'Usage des Modeles Machine Learning




Les 4 cas d'usage ML mis a jour : prediction du nombre d'activites, suivi de la desactivation a 30 ans, segmentation des profils (incluant Motatawi3), et repartition des equipements.

Resume des 4 modeles predictifs (mis a jour)

Modele	Question	Algorithme	Valeur pour le ministere
A — Prediction Activites	Combien d'activites vont avoir lieu le mois prochain ?	XGBoost / SARIMA	Anticiper les besoins logistiques des maisons de jeunes
B — Suivi Desactivation	Combien de beneficiaires vont atteindre 30 ans bientot ?	Regle deterministe	Anticiper le renouvellement de la base active
C — Clustering Profils	Quels sont les grands profils (incluant Motatawi3) ?	K-Means	Personnaliser les offres et le volontariat par segment
D — Repartition Equipements	Quels equipements offrir a chaque maison de jeunes ?	Gradient Boosting	Optimiser l'allocation de ressources materielles

7. LIVRABLES & STRUCTURE DU PROJET

A la fin du stage, trois types de livrables seront remis : le **code source documente**, la **documentation technique** et le **rapport de stage final**.



Organisation des fichiers et modules du projet (stack mise a jour).

Livrables details

Type	Livrable	Description
Code	Bases sources SQL	passjeunes_db_v2.sql (SQL Server) + jam3iya_db_v2.sql (MySQL)
Code	Scripts de simulation	Generation Python avec noms marocains authentiques
Code	Packages SSIS	Extraction, staging, transformation, chargement (.dtsx)
Code	Modele SSAS Tabular	Dimensions, hierarchies, mesures DAX
Code	Modeles ML	Modeles entraines, evalues et sauvegardes (Scikit-learn)
Code	Generation rapports PDF	Script auto-generation rapports (Python/ReportLab)
DataViz	Fichiers Power BI (.pbix)	Dashboards connectes en Live au modele SSAS
Docs	Documentation technique	Guides SSIS et SSAS, architecture, schema de donnees
Docs	Rapport final de stage	Rapport complet : contexte, methodes, resultats, perspectives

8. PLANNING PREVISIONNEL — 2 MOIS (8 SEMAINES)

Le stage est organise en 8 semaines, avec une progression logique des fondations vers les modules avances. La Semaine 1 (fondations) est terminee.




Diagramme de Gantt — Planning des 8 semaines de stage par phase et module.

Detail semaine par semaine

Semaine	Phase	Taches principales	Livrable
S1	Fondations	Simulation donnees + Bases sources SQL Server/MySQL + Modelisation DWH v2	Termine
S2	SSIS	Extract (Connection Managers) + Staging + Transform (Lookups)	Spots SSIS
S3	SSIS	Load DWH_MJCC + Planification SQL Server Agent	Pipeline operationnel
S4	SSAS	Modele Tabular : dimensions, relations, hierarchies	Modele deploye
S5	Power BI	Mesures DAX + 3 Dashboards	Dashboards complets
S6	ML	Prediction activites + Suivi desactivation	Modeles A & B
S7	ML	Clustering profils + Repartition equipements	Modeles C & D
S8	Cloture	Rapports PDF auto + Documentation + Rapport final	Tous les livrables

9. STACK TECHNIQUE COMPLETE (MISE A JOUR)

Voici l'ensemble des technologies utilisees, organisees par categorie. Le changement majeur par rapport a la version initiale est le passage de Python/Airflow/PostgreSQL a l'ecosysteme SQL Server (SSIS/SSAS), plus coherent avec les sources et Power BI.

Categorie	Technologie	Role dans le projet	Statut
Sources	SQL Server + MySQL	PassJeunesDB et jam3iya_db	Valide
ETL	SSIS	Extraction, staging, transformation, chargement	Valide
Orchestration	SQL Server Agent	Planification automatique des packages SSIS	Valide
Data Warehouse	SQL Server (DWH_MJCC)	Stockage central en schema en etoile	Valide
Couche analytique	SSAS Tabular	Mesures DAX, hierarchies, securite	Valide
DataViz	Power BI	Dashboards connectes en Live au modele SSAS	Valide
Machine Learning	Scikit-learn / XGBoost	Modeles predictifs (Python, hors SQL Server)	Valide
Simulation	Python (donnees marocaines)	Generation de donnees realistes	Valide
Rapports	ReportLab (Python)	Generation automatique de rapports PDF	Valide

Note pour l'encadrant : SQL Server (avec SSIS/SSAS) necessite une licence Developer (gratuite) ou Standard/Enterprise deja disponible en interne. Power BI Desktop est gratuit. Seul Python reste necessaire pour la simulation, le ML et les rapports.

Conclusion

Ce projet constitue une solution data complete et modulaire pour valoriser les donnees de PassJeunes, Jam3iya.ma et Motatawi3. Il apportera au MJCC une vision unifiee de l'activite des jeunes et des associations au Maroc, des outils de pilotage modernes via Power BI, et une capacite d'anticipation grace aux modeles predictifs. La stack SQL Server (SSIS/SSAS) garantit une integration native et une maintenance facilitee par les equipes IT du ministere.