

ⵜⴰⴷⵓⴷⴰ ⵜⴰⵎⴰⵔⵉⵜ
ⵜⴰⵎⴰⵔⵉⵜ ⵜⴰⵎⴰⵔⵉⵜ
ⵏ ⵜⴰⵎⴰⵔⵉⵜ ⵏ ⵜⴰⵎⴰⵔⵉⵜ



المملكة المغربية
وزارة الشباب
والثقافة والتواصل

Royaume du Maroc

Ministère de la Jeunesse, de la Culture et de la Communication

RAPPORT DE STAGE

Conception et mise en œuvre d'une plateforme décisionnelle et de modèles prédictifs pour le pilotage des programmes jeunesse

Réalisé par : Mohamed Ali Asri

Encadrante de stage : Khaoula Ben Addi

Filière académique : Big Data, IA et Applications Avancées

Stage effectué au sein du Ministère de la Jeunesse, de la Culture et de la Communication — secteur
Jeunesse

Juin – août 2026

Remerciements

Je tiens à exprimer ma sincère gratitude à l'ensemble des équipes du Ministère de la Jeunesse, de la Culture et de la Communication, filière Jeunesse, pour leur accueil et l'accompagnement apporté tout au long de ce stage.

Mes remerciements s'adressent en particulier à mon encadrante de stage, Mme Khaoula Ben Addi, pour sa disponibilité, ses conseils techniques et méthodologiques, ainsi que pour la confiance accordée dans la conduite de ce projet, depuis la phase de cadrage jusqu'à la restitution finale.

Je remercie également l'ensemble des personnes ayant contribué, de près ou de loin, à la réussite de ce travail, ainsi que le corps enseignant de ma formation pour les bases méthodologiques transmises et mobilisées tout au long de ce projet.

Résumé

Ce rapport présente le travail réalisé lors d'un stage effectué au sein du Ministère de la Jeunesse, de la Culture et de la Communication (filière Jeunesse), portant sur la conception d'une plateforme décisionnelle consolidant deux systèmes d'information jusque-là cloisonnés : PassJeunes (avantages et réductions destinés aux jeunes, sous SQL Server) et Jam3iya.ma (vie associative et maisons de jeunes, sous MySQL).

Le projet couvre l'ensemble de la chaîne de valeur décisionnelle : intégration des données par des flux ETL sous SQL Server Integration Services (SSIS), consolidation dans un entrepôt de données modélisé en schéma en étoile (DWH_MJCC), construction d'un modèle sémantique analytique sous SSAS Tabular (17 mesures DAX), et restitution à travers un tableau de bord Power BI structuré en six pages métier. Le projet intègre également un volet de Data Science à part entière, avec quatre modèles de Machine Learning couvrant la prédiction du désengagement des bénéficiaires (F1-score de 0,62), la segmentation comportementale (K-Means, 3 segments), la recommandation personnalisée d'offres et la propension à l'engagement associatif — ce dernier modèle répondant directement à la problématique de transversalité à l'origine du projet.

Une relecture critique du modèle, conduite en fin de projet, a permis d'identifier des axes de fiabilisation concrets (typage des dates, comportement de filtrage de certaines mesures, redondances de modélisation), restitués sous forme de recommandations priorisées en fin de rapport. Les données à caractère personnel utilisées sont intégralement synthétiques, pour des raisons de confidentialité institutionnelle ; seul le référentiel des offres partenaires est réel.

Mots-clés : *Business Intelligence, Data Warehouse, schéma en étoile, ETL, SSIS, SSAS Tabular, DAX, Power BI, Machine Learning, jeunesse, secteur public.*

Sommaire

1. Introduction générale.....	1
2. Présentation de l'organisme d'accueil.....	1
3. Contexte et problématique du projet.....	2
4. Méthodologie et planning du stage.....	4
5. Architecture technique globale.....	5
6. Sources de données et modélisation transactionnelle (OLTP).....	6
7. Zone de Staging et flux d'intégration (ETL SSIS).....	7
8. Le Data Warehouse — modélisation en schéma en étoile.....	13
9. Modèle sémantique SSAS Tabular et mesures analytiques (DAX).....	16
10. Le tableau de bord Power BI.....	19
11. Volet Data Science : les modèles de Machine Learning.....	24
12. Résultats, apports pour le Ministère et limites du projet.....	27
13. Conclusion générale.....	29
Annexe A — Extrait de code SQL : génération de la dimension temporelle.....	30
Annexe B — Glossaire et liste des abréviations.....	31
Annexe C — Environnement technique.....	31
Annexe D — Diagrammes entité-relation détaillés des systèmes sources.....	32

Table des figures

Figure 1 — Modèle de données des systèmes sources PassJeunes et Jam3iya

Figure 2 — Connection Manager OLE DB vers PassJeunesDB

Figure 3 — Connection Manager ADO.NET vers jam3iya_db

Figure 4 — Connection Manager OLE DB vers STAGING_MJCC

Figure 5 — Séquences SEQ_PassJeunes_SQLServer et SEQ_Jam3iya_MySQL

Figure 6 — Orchestration via le Master Package

Figure 7 — Exécution réussie du chargement Staging (PassJeunesDB)

Figure 8 — Exécution réussie du chargement Staging (jam3iya_db)

Figure 9 — ADO.NET Source Editor (contournement MySQL)

Figure 10 — OLE DB Source Editor (SQL Server)

Figure 11 — Schéma en étoile physique de DWH_MJCC

Figure 12 — Control Flow SSIS d'alimentation du DWH

Figure 13 — Page « Synthèse Exécutive » du tableau de bord

Figure 14 — Page « Analyse des Opérations & Offres »

Figure 15 — Page « Volontariat Motatawi3 »

Figure 16 — Page « Vie Associative & Maisons de Jeunes »

Figure 17 — Page « Démographie & Inclusion »

Figure 18 — Page « Intelligence Artificielle & Machine Learning »

Figure 19 — Comparaison des cinq modèles de prédiction du churn

Figure 20 — Importance des variables du modèle de churn

Figure 21 — Taux de churn par tranche d'âge et par genre

Figure 22 — Tableau de bord de segmentation K-Means

Figure 23 — Tableau de bord du moteur de recommandation

Figure 24 — Diagramme entité-relation détaillé de PassJeunesDB

Figure 25 — Diagramme entité-relation détaillé de jam3iya_db

1. Introduction générale

Ce rapport présente le travail réalisé dans le cadre d'un stage effectué au sein du Ministère de la Jeunesse, de la Culture et de la Communication, filière Jeunesse. Le stage s'est déroulé au sein des équipes en charge du suivi des programmes destinés à la jeunesse marocaine, et plus particulièrement des plateformes PassJeunes (avantages et réductions destinés aux jeunes) et Jam3iya.ma (recensement et suivi de la vie associative et des maisons de jeunes).

À mon arrivée, le constat était le suivant : ces deux plateformes reposent sur des systèmes d'information distincts, techniquement hétérogènes (SQL Server pour PassJeunes, MySQL pour Jam3iya.ma), sans aucun mécanisme permettant de croiser leurs données. Les responsables du Ministère ne disposaient donc d'aucune vision consolidée de l'impact réel des programmes jeunesse : impossible, par exemple, de savoir si un jeune bénéficiaire du PassJeunes s'engage également dans la vie associative locale, ou de mesurer objectivement l'utilisation réelle des crédits alloués par région.

L'objectif du stage a été de concevoir et de mettre en œuvre une infrastructure décisionnelle complète permettant de répondre à ce besoin : extraire, consolider et modéliser les données issues des deux systèmes sources dans un entrepôt de données (Data Warehouse), construire un modèle sémantique analytique, puis restituer ces informations à travers un tableau de bord Power BI destiné aux directeurs et responsables de programmes du Ministère. Le projet a également été enrichi d'un volet Data Science, avec le développement de quatre modèles de Machine Learning visant à anticiper certains comportements des bénéficiaires (risque de désengagement, propension à l'engagement associatif, segmentation, recommandation d'offres).

Ce rapport est structuré en suivant la chaîne de valeur de la donnée, de la source jusqu'à la restitution : présentation de l'organisme d'accueil et du contexte du projet, architecture technique globale, sources de données et modélisation transactionnelle, zone de transit (staging) et flux d'intégration (ETL), modélisation du Data Warehouse en schéma en étoile, modèle sémantique et mesures analytiques (DAX), tableau de bord Power BI, puis volet Machine Learning. Le rapport se conclut par un bilan des apports du projet pour le Ministère, ses limites actuelles et les perspectives d'évolution envisagées.

2. Présentation de l'organisme d'accueil

2.1. Le Ministère de la Jeunesse, de la Culture et de la Communication

Le Ministère de la Jeunesse, de la Culture et de la Communication est chargé, à travers sa filière Jeunesse, de la conception et de la mise en œuvre des politiques publiques en direction des jeunes marocains. Cette mission recouvre notamment l'animation du réseau des maisons de jeunes réparties sur l'ensemble du territoire national, le soutien au tissu associatif local, l'organisation de programmes de volontariat, ainsi que la gestion de dispositifs d'accompagnement direct des jeunes, à travers des avantages tarifaires et des réductions auprès de partenaires publics et privés.

Le stage s'est déroulé au sein d'une équipe transverse en charge du pilotage et du suivi de ces programmes, dans un contexte de digitalisation croissante des outils de gestion du secteur jeunesse.

2.2. Les programmes concernés par le projet

- PassJeunes : dispositif permettant aux jeunes inscrits de bénéficier de réductions et d'avantages auprès d'un réseau de partenaires (culture, santé, formation, banque, loisirs, etc.), avec un système de crédit annuel alloué par bénéficiaire et consommé au fil des opérations.
- Jam3iya.ma : plateforme de recensement des maisons de jeunes et des associations, de leurs adhérents et des activités organisées (colonies de vacances, ateliers, événements), avec suivi des budgets alloués et consommés ainsi que des taux de satisfaction des participants.
- Motatawi3 : programme de volontariat associé à PassJeunes, permettant aux jeunes de s'inscrire à des missions de bénévolat organisées par édition, classées par domaine d'intervention.

Ces trois dispositifs, bien que gérés par des équipes et des systèmes d'information distincts, ciblent la même population de jeunes bénéficiaires et poursuivent un objectif institutionnel commun : renforcer l'engagement et l'épanouissement de la jeunesse marocaine. C'est précisément cette absence de lien technique entre des dispositifs institutionnellement liés qui constitue le point de départ de ce projet.

3. Contexte et problématique du projet

3.1. Un cloisonnement technique entre systèmes d'information

Le système PassJeunes repose sur une base de données SQL Server (PassJeunesDB), tandis que la plateforme Jam3iya.ma repose sur une base MySQL (jam3iya_db). Ces deux environnements ont été développés indépendamment, avec des modèles de données, des conventions de nommage et des technologies différentes. En conséquence, aucune requête ni aucun outil de reporting ne permettait, avant ce projet, de croiser les données des deux systèmes : il était par exemple impossible de savoir en combien de temps un jeune bénéficiaire du PassJeunes rejoint une association Jam3iya, ou de comparer le dynamisme associatif d'une région à l'usage réel des avantages PassJeunes dans cette même région.

3.2. Les limites d'une interrogation directe des bases de production

Une première option aurait consisté à interroger directement les deux bases de production pour produire des rapports ponctuels. Cette approche présente plusieurs inconvénients majeurs dans un contexte institutionnel : risque de saturation des bases transactionnelles utilisées en temps réel par les applications métier, absence d'historisation (les bases OLTP ne conservent généralement que l'état courant), hétérogénéité des schémas rendant les jointures inter-bases complexes et peu performantes, et absence de couche d'agrégation adaptée à l'analyse décisionnelle. Ces limites justifient le recours à une architecture décisionnelle dédiée, découplée des systèmes de production.

3.3. Objectifs assignés au projet

Le projet a été cadré autour des objectifs suivants, fixés en lien avec les besoins exprimés par les responsables de programmes :

- Centraliser dans un entrepôt de données unique les informations issues de PassJeunesDB et de jam3iya_db, sans impacter les performances des systèmes de production.
- Modéliser ces données selon les standards de la Business Intelligence (schéma en étoile) afin de permettre des analyses transverses et performantes.

- Mettre à disposition des directeurs du Ministère un outil de pilotage visuel et interactif (tableau de bord Power BI), organisé par thématique métier (opérations et offres, volontariat, vie associative, démographie).
- Aller au-delà du reporting descriptif classique en introduisant une dimension prédictive, permettant d'anticiper certains comportements des bénéficiaires (risque de désengagement, potentiel d'engagement associatif) pour outiller une action publique plus proactive.

3.4. Une précision méthodologique importante sur la nature des données

Pour des raisons de confidentialité institutionnelle, l'ensemble des données à caractère personnel ou opérationnel manipulées dans ce projet (profils des bénéficiaires, opérations, soldes, associations, activités) sont des données synthétiques, générées par des scripts Python dédiés, reproduisant statistiquement la structure et la volumétrie de données réelles (environ 10 000 bénéficiaires simulés, plus de 400 000 opérations, 500 associations). Seul le référentiel des offres PassJeunes proposées par les partenaires (catégories, types d'avantages, conditions) correspond à des offres réellement existantes, communicables sans risque de confidentialité. Cette approche a permis de conduire l'intégralité du projet — de la modélisation à la restitution décisionnelle — dans des conditions de volumétrie et de complexité représentatives d'un contexte réel, sans exposer aucune donnée personnelle effective. Cette précision est essentielle à la bonne lecture des résultats chiffrés présentés dans ce rapport, en particulier ceux issus des modèles de Machine Learning.

3.5. Règles de gestion métier identifiées et formalisées

La phase de conception a nécessité un travail de clarification des règles de gestion implicites régissant les deux plateformes sources, afin qu'elles soient correctement reproduites dans les données de test puis respectées par le modèle décisionnel. Les principales règles formalisées sont les suivantes :

- Désactivation automatique du PassJeunes à 30 ans : un bénéficiaire est considéré comme désactivé dès que sa date de naissance additionnée de 30 années est dépassée (`date_naissance + 30 ans`), indépendamment de toute action explicite. Cette règle, identifiée lors de l'analyse du modèle source, explique en grande partie certains résultats du modèle de prédiction du désengagement présentés en section 11.1.
- Périmètre restreint du programme Motatawi3 : le volontariat est réservé au sous-ensemble des bénéficiaires âgés de 18 à 22 ans, alors que le PassJeunes lui-même couvre une tranche plus large (16 à 30 ans).
- Lien inter-plateformes fondé sur le CIN : le rapprochement d'un même individu entre PassJeunes et Jam3iya.ma (pour déterminer, par exemple, si un bénéficiaire PassJeunes est membre d'une association) repose exclusivement sur la correspondance du numéro de CIN entre les deux systèmes, d'où l'importance du déclencheur de validation de cohérence mis en place dès la source (voir section 6.3).
- Fusion des rôles « Animateur » et « Membre du Bureau » : dans le modèle Jam3iya, ces deux rôles associatifs distincts sont portés par une unique table `Personne_Association`, différenciée par l'attribut `type_personne`, plutôt que par deux tables séparées — un choix de modélisation à respecter lors de toute évolution du modèle.

Modèle de Données MJCC




Figure 1 — Modèle de données des systèmes sources PassJeunes (SQL Server) et Jam3iya (MySQL), avec règles de gestion et liens inter-plateformes.

4. Méthodologie et planning du stage

Le projet a été conduit selon une démarche séquentielle, chaque phase produisant un livrable conditionnant le démarrage de la suivante — logique imposée par la nature même d'un projet décisionnel, où la fiabilité de la restitution finale dépend directement de la qualité des couches situées en amont (sources, staging, entrepôt). Le tableau suivant synthétise les six grandes phases du stage, leurs objectifs et leurs livrables associés.

Phase	Objectif	Livrable principal
1. Cadrage et analyse	Comprendre les systèmes sources, formaliser les règles de gestion et cadrer les besoins décisionnels du Ministère	Notes de cadrage, modèle de données des sources (MCD)
2. Génération des données de test	Constituer un jeu de données représentatif (volumétrie et structure) dans le respect de la confidentialité institutionnelle	Scripts Python de génération, bases PassJeunesDB et jam3iya_db peuplées
3. Intégration ETL (SSIS)	Extraire et charger les données sources vers la zone de Staging de façon fiable et rejouable	Packages SSIS, base STAGING_MJCC
4. Modélisation du Data Warehouse	Concevoir et déployer le schéma en étoile (dimensions et faits)	Base DWH_MJCC, scripts SQL documentés
5. Modèle sémantique et restitution	Construire le cube SSAS Tabular, écrire les mesures DAX et développer le tableau de bord Power BI	Modèle SSAS_MJCC, fichier MJCC_Dashboard.pbix

Phase	Objectif	Livrable principal
6. Volet Data Science	Développer, évaluer et intégrer les quatre modèles de Machine Learning au pipeline décisionnel	Scripts Python, scores intégrés au DWH et au cube

Cette organisation en phases n'a pas empêché des retours en arrière ponctuels — notamment lors de la phase d'intégration ETL, où plusieurs anomalies techniques (détaillées en section 7.3) ont nécessité de revenir sur des choix de la phase de cadrage. Cette itération est volontairement documentée dans ce rapport plutôt que masquée, car elle reflète fidèlement la réalité d'un projet décisionnel mené en environnement réel : la définition des règles de gestion se précise et se corrige au contact des données, et non uniquement lors de la phase de conception initiale.

Sur le plan des outils, le suivi du projet a été assuré au moyen de notes de suivi hebdomadaires transmises à l'encadrant de stage, formalisant l'avancement, les blocages rencontrés et les décisions de conception prises à chaque étape — démarche qui a notamment permis d'arbitrer collectivement les choix de dénormalisation du modèle en étoile présentés en section 8.4.

5. Architecture technique globale

L'architecture retenue suit la chaîne de valeur classique d'un projet décisionnel, en cinq couches successives, chacune ayant un rôle précis et une raison d'être technique :

- Couche Sources : les deux bases transactionnelles (OLTP) PassJeunesDB (SQL Server) et jam3iya_db (MySQL), qui restent la propriété exclusive des applications métier et ne sont jamais modifiées par le projet décisionnel.
- Couche Staging : une base tampon (STAGING_MJCC) recevant une copie brute des données sources, permettant d'isoler la charge d'extraction des bases de production et de disposer d'un point de contrôle intermédiaire avant transformation.
- Couche Data Warehouse : l'entrepôt de données DWH_MJCC, modélisé en schéma en étoile, qui consolide et historise les données des deux sources selon une logique orientée analyse (dimensions et faits).
- Couche modèle sémantique : un cube SSAS Tabular (SSAS_MJCC), qui charge en mémoire les données du DWH, y ajoute des hiérarchies de navigation et des mesures calculées en langage DAX.
- Couche restitution : le tableau de bord Power BI, connecté au cube SSAS et enrichi des sorties des modèles de Machine Learning, qui constitue le point d'entrée final pour les utilisateurs métier.

Ce découplage en couches successives répond à un principe fondamental de l'ingénierie décisionnelle : chaque couche a une responsabilité unique (extraction, stockage brut, modélisation analytique, calcul de mesures, restitution visuelle), ce qui facilite la maintenance, la traçabilité des anomalies et l'évolution indépendante de chaque composant. Le choix technologique s'est porté sur l'écosystème Microsoft (SQL Server, SSIS, SSAS Tabular, Power BI) en cohérence avec l'infrastructure déjà en place au sein du Ministère et la disponibilité des licences correspondantes.

Un point d'attention architectural mérite d'être souligné : le tableau de bord final n'est pas alimenté uniquement par le cube SSAS en connexion live. Il s'agit d'un modèle composite associant une connexion live vers SSAS_MJCC pour l'ensemble des indicateurs de gestion courants (opérations, soldes, activités, volontariat), et un import complémentaire de données pour les scores issus des modèles de Machine Learning. Ce choix est détaillé et justifié dans la section consacrée au volet Machine Learning (section 11), où l'on montre que ces scores ne sont en réalité pas importés de façon ad hoc mais réintégrés au Data Warehouse puis au cube via un pipeline automatisé, avant d'être consommés dans Power BI.

Le tableau ci-dessous détaille, pour chaque couche de l'architecture, le composant technique retenu, son rôle précis et la technologie mobilisée :

Couche	Composant	Rôle / Technologie
Sources (OLTP)	PassJeunesDB / jam3iya_db	Bases de production, non modifiées ; SQL Server / MySQL
Staging	STAGING_MJCC	Zone tampon sans contrainte, isolant les bases de production ; SQL Server
Intégration	Projet ETL_MJCC	Extraction, purge, chargement, orchestration ; SQL Server Integration Services (SSIS)
Entrepôt de données	DWH_MJCC	Modélisation en étoile, historisation ; SQL Server
Modèle sémantique	SSAS_MJCC	Hiérarchies, relations, mesures DAX, moteur en mémoire ; SSAS Tabular (VertiPaq)
Restitution	MJCC_Dashboard.pbix	Visualisation interactive, modèle composite (live + import) ; Power BI Desktop
Volet prédictif	Scripts ML_Churn, ML_Segmentation, ML_Recommandation, ML_Engagement_Associatif	Entraînement, scoring, écriture retour vers le DWH ; Python (scikit-learn, XGBoost)

6. Sources de données et modélisation transactionnelle (OLTP)

6.1. PassJeunesDB (SQL Server)

La base PassJeunesDB regroupe six tables couvrant l'ensemble du cycle de vie d'un bénéficiaire PassJeunes : Beneficiaire (profil du jeune : identité, genre, date de naissance, statut, situation de handicap), Partenaire (entités proposant des avantages), Offre_PassJeunes (catalogue des offres, rattachées à un partenaire), Solde (crédit annuel alloué à chaque bénéficiaire par offre), Operation (chaque utilisation effective d'une offre par un bénéficiaire), et Motatawi3 (inscriptions au programme de volontariat). Cette base a été peuplée avec un volume représentatif de 10 000 bénéficiaires, 24 partenaires et plus de 400 000 opérations, générés par un script Python dédié (generate_source_data.py).

6.2. jam3iya_db (MySQL)

La base jam3iya_db regroupe sept tables couvrant la vie associative : maison_jeunes (structures d'accueil), association (entités associatives, avec type, domaine d'activité et statut), personne_association (adhérents), colonie_vacances, activite (activités organisées, avec budget alloué et consommé), rapport_activite (bilan des activités : participants, taux de satisfaction) et cin_beneficiaires_valides (table de contrôle de cohérence des identités). Elle a été peuplée avec environ 500 associations et leur volume d'activités associé.

Base	Table	Rôle
PassJeunesDB	Beneficiaire	Profil des jeunes inscrits au dispositif
PassJeunesDB	Partenaire	Entités proposant des avantages
PassJeunesDB	Offre_PassJeunes	Catalogue des offres, rattachées à un partenaire
PassJeunesDB	Solde	Crédit annuel alloué par bénéficiaire et par offre
PassJeunesDB	Operation	Historique des utilisations effectives d'une offre
PassJeunesDB	Motatawi3	Inscriptions au programme de volontariat
jam3iya_db	maison_jeunes	Structures d'accueil de proximité
jam3iya_db	association	Associations recensées (type, domaine, statut)
jam3iya_db	personne_association	Adhérents et rôles associatifs (membre, animateur)
jam3iya_db	colonie_vacances	Colonies et campus saisonniers organisés
jam3iya_db	activite	Activités organisées, avec budget alloué
jam3iya_db	rapport_activite	Bilan des activités (participants, satisfaction, budget consommé)
jam3iya_db	cin_beneficiaires_valides	Table de contrôle du rapprochement inter-plateformes

6.3. Choix de modélisation et contrôles de cohérence

Les deux bases ont été conçues avec des contraintes d'intégrité référentielle strictes (clés étrangères, contraintes CHECK), afin de garantir dès la source la fiabilité des données injectées dans le pipeline décisionnel. Un déclencheur (trigger) spécifique, fk_validation_cin_trigger, a par ailleurs été mis en place pour valider la cohérence des numéros de CIN entre les deux systèmes lors de l'intégration, condition indispensable au rapprochement ultérieur d'un même bénéficiaire à travers PassJeunes et Jam3iya.ma.

Durant la phase de génération des données de test, un premier écueil a été identifié et corrigé : la fonction Python de génération des dates de naissance produisait, dans certains cas, un âge décalé d'une année par rapport au calcul natif DATEDIFF(YEAR) de SQL Server, en raison d'une différence de méthode de calcul d'âge entre les deux environnements. Cette anomalie a été corrigée directement dans le script

générateur, illustrant l'importance de valider la cohérence des règles métier non seulement au niveau du schéma, mais aussi au niveau des données elles-mêmes.

Les diagrammes entité-relation complets, avec cardinalités détaillées, des deux bases sources sont fournis en Annexe D pour référence technique approfondie.

7. Zone de Staging et flux d'intégration (ETL SSIS)

7.1. Rôle de la zone de Staging

La base STAGING_MJCC constitue une zone tampon intermédiaire entre les sources et le Data Warehouse. Elle comprend treize tables : six tables reprenant à l'identique la structure des tables PassJeunesDB (stg_passjeunes_*), six tables reprenant celle de jam3iya_db (stg_jam3iya_*), sans contrainte de clé étrangère ni de contrôle CHECK afin de ne jamais bloquer un chargement en cas d'anomalie de donnée source, et une table etl_log assurant la traçabilité de chaque exécution (horodatage, nombre de lignes traitées, statut).

7.2. Architecture des packages SSIS

Le projet SSIS ETL_MJCC orchestre l'ensemble des flux via trois gestionnaires de connexion (Connection Managers) : un accès OLE DB vers PassJeunesDB, un accès OLE DB vers STAGING_MJCC, et un accès ADO.NET vers jam3iya_db (MySQL.Data.MySqlClient). Deux séquences de traitement s'exécutent en parallèle : SEQ_PassJeunes_SQLServer, qui gère six flux (un par table source, chacun structuré en TRUNCATE de la table de staging suivi d'un Data Flow de chargement), et SEQ_Jam3iya_MySQL, organisée selon le même principe pour les six tables MySQL.

Séquence	Nombre de flux	Tables de staging alimentées
SEQ_PassJeunes_SQLServer	6	stg_beneficiaire, stg_partenaire, stg_offre, stg_solde, stg_operation, stg_motatawi3
SEQ_Jam3iya_MySQL	6	stg_maison_jeunes, stg_association, stg_personne_association, stg_colonie_vacances, stg_activite, stg_rapport_activite




Figure 2 — Connection Manager OLE DB vers PassJeunesDB (authentification Windows).




Figure 3 — Connection Manager ADO.NET (.Net Providers\MySQL Data Provider) vers jam3iya_db.




Figure 4 — Connection Manager OLE DB vers STAGING_MJCC.

Chaque flux de la zone de Staging suit un motif identique — une tâche Execute SQL (purge de la table cible par TRUNCATE) suivie d'une tâche Data Flow (chargement) — répété pour chacune des douze tables sources, comme illustré par les deux séquences ci-dessous.



Figure 5 — Détail des séquences SEQ_PassJeunes_SQLServer (haut) et SEQ_Jam3iya_MySQL (bas) dans SSIS.

L'ensemble de ce cycle — purge du Staging, rechargement, alimentation des dimensions du DWH, puis alimentation des tables de faits — est orchestré par un Master Package unique (illustré en figure 12),

permettant de relancer l'intégralité du pipeline en une seule exécution, condition nécessaire à une future automatisation de la fraîcheur des données (rafraîchissement planifié).




Figure 6 — Orchestration du pipeline complet via le Master Package (EXEC_Extraction_Staging → EXEC_Load_DWH).

L'exécution réussie des deux séquences d'extraction, telle que rapportée par l'environnement SSIS (coche verte sur chaque tâche), confirme la fiabilité du pipeline sur l'ensemble des tables sources des deux systèmes.




Figure 7 — Exécution réussie du flux de chargement Staging pour PassJeunesDB.




Figure 8 — Exécution réussie du flux de chargement Staging pour jam3iya_db.

7.3. Difficultés techniques rencontrées et solutions apportées

Plusieurs difficultés concrètes ont été rencontrées et documentées durant cette phase, ce qui a permis de consolider une réelle expérience de mise en production d'un flux ETL :

- Une erreur de type « DTSRuntimeWrap Library not registered » a nécessité l'exécution de Visual Studio en mode administrateur pour permettre l'enregistrement correct des composants runtime SSIS.
- Le pilote ADO.NET MySQL ne parvenait pas à charger la liste des tables ou vues disponibles (« No tables or views could be loaded »). Ce problème a été contourné en remplaçant le mode de sélection « Table or view » par une requête SQL explicite (« SQL command ») dans les Data Flow concernés, comme le montre la figure 15 ci-dessous, à comparer avec le mode « Table or view » resté fonctionnel côté SQL Server (figure 16).
- Un avertissement de troncature est apparu sur la colonne nom lors du chargement : après analyse, il a été jugé sans impact réel sur la qualité de la donnée (marge de longueur suffisante en pratique) et volontairement ignoré, plutôt que de sur-dimensionner artificiellement la colonne.
- Une incohérence sur la clé de substitution (IDENTITY) de la table Solde, provoquée par des tentatives d'insertion échouées ayant fait avancer le compteur, a nécessité une réinitialisation complète du schéma source (DROP puis CREATE) avant une nouvelle insertion des données.




Figure 9 — ADO.NET Source Editor : contournement par requête SQL explicite (mode « SQL command ») pour la table *personne_association* (MySQL).




Figure 10 — OLE DB Source Editor : mode « Table or view » resté fonctionnel côté SQL Server pour la table Beneficiaire.

8. Le Data Warehouse — modélisation en schéma en étoile

Le cœur analytique du projet repose sur l'entrepôt de données DWH_MJCC, modélisé selon un schéma en étoile (star schema), standard de référence en Business Intelligence pour son équilibre entre simplicité de compréhension métier et performance des requêtes analytiques. Cette modélisation sépare explicitement les axes d'analyse (dimensions) des indicateurs mesurables (faits), comme le montre le diagramme physique ci-dessous, extrait directement de l'environnement de conception du DWH.




Figure 11 — Schéma en étoile physique de DWH_MJCC : 6 dimensions et 4 tables de faits.

8.1. Les dimensions

- **dim_temps** : dimension temporelle couvrant la période 2018-2026, générée automatiquement par une requête récursive T-SQL. Elle porte la hiérarchie Année → Trimestre → Mois → Jour et inclut des attributs dérivés (nom du jour, nom du mois, indicateur de week-end, numéro de semaine ISO), permettant une navigation temporelle riche sans calcul à la volée.
- **dim_region** : dimension géographique portant la hiérarchie Zone Géographique → Région → Ville, structurée selon le découpage administratif du Maroc (Nord, Centre, Sud, Est, Sahara).
- **dim_beneficiaire** : dimension centrale du modèle, portant le profil de chaque jeune bénéficiaire (genre, tranche d'âge, statut, situation de handicap, statut d'adhésion au PassJeunes, dates de naissance et d'inscription).
- **dim_offre** : dimension des offres PassJeunes, dans laquelle les informations du partenaire (nom, secteur d'activité) ont été volontairement fusionnées avec celles de l'offre elle-même (catégorie, type d'avantage, tarifs, conditions), afin de limiter le nombre de jointures nécessaires lors de l'analyse d'une opération sans dégrader la richesse d'analyse par partenaire.
- **dim_association** : dimension des associations Jam3iya (type, domaine d'activité, statut, nombre de membres).
- **dim_maison_jeunes** : dimension des structures d'accueil (capacité, statut, date d'ouverture).

8.2. Les tables de faits

Quatre tables de faits couvrent les quatre grands processus métier suivis par le Ministère :

- fait_operations : grain = une ligne par opération (chaque utilisation d'une offre par un bénéficiaire). Mesures : montant_reduction, nb_operations. Clés étrangères vers dim_temps, dim_region, dim_beneficiaire et dim_offre, chacune indexée pour optimiser les jointures analytiques.
- fait_solde : grain = un solde de crédit annuel par couple bénéficiaire/offre. Mesures : credit_initial, credit_restant, et une colonne calculée et persistée credit_consomme (= credit_initial - credit_restant), calculée directement au niveau SQL plutôt qu'en couche analytique, ce qui garantit une valeur unique et cohérente quel que soit l'outil qui l'interroge.
- fait_activites : grain = une activité associative avec son rapport de bilan. Mesures : budget, budget_consomme, nb_participants, taux_satisfaction, duree_jours. Clés étrangères vers dim_temps, dim_region, dim_association et dim_maison_jeunes.
- fait_motatawi3 : grain = une inscription au programme de volontariat. Attributs : édition du programme, domaine de volontariat, niveau d'études, statut du dossier. Clés étrangères vers dim_temps, dim_region et dim_beneficiaire.

Le chargement du DWH suit une logique séquentielle stricte, imposée par les contraintes de clé étrangère : purge des tables cibles, puis alimentation des six dimensions en parallèle (SEQ_Load_Dimensions), et enfin, seulement une fois les dimensions chargées, alimentation des quatre tables de faits (SEQ_Load_Faits), qui référencent ces dimensions.



Figure 12 — Control Flow SSIS d'alimentation du DWH : purge, puis chargement parallèle des dimensions, puis des faits.

8.3. Dictionnaire de données synthétique

Le tableau ci-dessous synthétise, pour chaque table du Data Warehouse, son rôle, son grain et ses attributs les plus significatifs, à titre de référence rapide pour la lecture du modèle.

Table	Grain / rôle	Attributs clés
dim_temps	1 ligne = 1 jour calendaire (2018–2026)	temps_id, date_complete, jour, mois, annee, trimestre, nom_jour, nom_mois, est_weekend
dim_region	1 ligne = 1 ville	region_id, ville, region, zone_geo
dim_beneficiaire	1 ligne = 1 bénéficiaire PassJeunes	beneficiaire_id, cin, genre, tranche_age, type_statut, en_situation_handicap, statut_pass, date_inscription, est_membre_association
dim_offre	1 ligne = 1 offre partenaire	offre_id, nom_offre, categorie, type_avantage, nom_partenaire, secteur, tarif
dim_association	1 ligne = 1 association Jam3iya	association_id, nom, type, domaine_activite, statut, nb_membres
dim_maison_jeunes	1 ligne = 1 structure d'accueil	maison_id, nom, ville, capacite_accueil, statut
fait_operations	1 ligne = 1 opération (usage d'une offre)	temps_id, region_id, beneficiaire_id, offre_id, montant_reduction
fait_solde	1 ligne = 1 solde annuel (bénéficiaire × offre × année)	beneficiaire_id, offre_id, annee, credit_initial, credit_restant, credit_consomme
fait_activites	1 ligne = 1 activité avec bilan	association_id, maison_id, temps_id, region_id, budget, budget_consomme, nb_participants, taux_satisfaction
fait_motatawi3	1 ligne = 1 inscription au volontariat	beneficiaire_id, temps_id, region_id, edition, domaine_volontariat, niveau_etudes, statut_dossier

8.4. Choix de conception et points de vigilance identifiés

La conception du schéma en étoile a nécessité plusieurs arbitrages qu'il est utile d'explicitier, dans une logique d'amélioration continue du modèle :

- Dénormalisation de dim_offre : intégrer les attributs du partenaire directement dans la dimension offre simplifie le modèle et améliore les performances de requête, au prix d'une duplication de l'information partenaire sur chaque offre d'un même partenaire. Ce choix reste pertinent tant que le rapport offres/partenaire demeure faible (24 partenaires pour un catalogue d'offres limité), mais mériterait d'être reconsidéré si le nombre d'offres par partenaire venait à croître significativement.
- Double référence temporelle sur fait_solde : cette table combine à la fois un attribut annee et une clé étrangère temps_id vers la dimension de temps complète (au grain jour). Or le grain métier de cette table est annuel. Cette redondance, identifiée lors d'une relecture critique du modèle, devrait être clarifiée : soit en supprimant la clé temps_id au profit d'un lien direct au niveau année de

dim_temps, soit en documentant explicitement quelle date conventionnelle (par exemple le 1er janvier de l'exercice) est utilisée pour peupler temps_id, afin d'éviter tout drill-down erroné au niveau mois ou jour sur cette table.

- Typage des colonnes de dates dans dim_beneficiaire : les colonnes date_naissance et date_inscription sont typées en chaîne de caractères (string) plutôt qu'en date native, à la fois dans le schéma SQL du DWH et dans le modèle SSAS. Ce choix, hérité de la phase de génération des données sources, limite l'exploitation native des fonctionnalités d'intelligence temporelle (Time Intelligence) de DAX sur ces colonnes et devrait être corrigé en priorité lors d'une prochaine itération, en les convertissant en type DATE dès l'étape ETL.

L'ensemble des clés étrangères des tables de faits est indexé, ce qui, combiné à la volumétrie actuelle (environ 400 000 lignes pour fait_operations), garantit des temps de réponse compatibles avec un usage interactif dans Power BI, d'autant que le moteur en mémoire (VertiPaq) du modèle SSAS Tabular applique une compression columnaire particulièrement efficace sur ce type de structure en étoile.

9. Modèle sémantique SSAS Tabular et mesures analytiques (DAX)

9.1. Rôle du modèle sémantique

Le Data Warehouse constitue la couche de stockage et de modélisation relationnelle, mais ne porte pas en lui-même de logique de calcul analytique. Cette responsabilité est confiée au cube SSAS Tabular (SSAS_MJCC), déployé en mode In-Memory sur une instance locale. Ce modèle importe l'ensemble des dimensions et des tables de faits du DWH, y ajoute des hiérarchies de navigation adaptées à l'usage métier, et porte l'ensemble des mesures calculées en langage DAX (Data Analysis Expressions) consommées ensuite par Power BI.

9.2. Relations et hiérarchies

Le modèle comporte quinze relations, dont quatorze relations actives de type dimension → fait (à sens unique, conformément aux bonnes pratiques du schéma en étoile), et une quinzième relation reliant directement dim_beneficiaire (via sa date d'inscription) à dim_temps (via sa date complète), volontairement laissée inactive par défaut (représentée en pointillés dans le diagramme du modèle). La table dim_temps est explicitement déclarée comme table de dates du modèle (Date Table), condition nécessaire à l'utilisation correcte des fonctions d'intelligence temporelle de DAX. Deux hiérarchies de navigation ont été construites : une hiérarchie Calendrier (Année → Trimestre → Mois → Jour) et une hiérarchie Géographie (Région → Ville), permettant aux utilisateurs de Power BI d'effectuer des analyses en exploration progressive (drill-down) sans manipulation technique.

9.3. Les mesures DAX du modèle

Dix-sept mesures ont été développées et réparties sur les tables du modèle, présentées dans le tableau suivant :

Table	Mesure	Objectif métier
fait_operations	Total_Operations	Nombre total d'opérations (utilisations d'offres)
fait_operations	Montant_Total_Reductions	Montant cumulé des réductions accordées
fait_operations	Montant_Moyen_Reduction	Montant moyen d'une réduction
fait_operations	Nb_Beneficiaires_Actifs	Nombre de bénéficiaires distincts ayant réalisé au moins une opération
fait_solde	Credit_Initial_Total	Somme des crédits annuels alloués
fait_solde	Credit_Restant_Total	Somme des crédits non consommés
fait_solde	Credit_Consomme_Total	Montant total du crédit effectivement utilisé
fait_solde	Taux_Utilisation_Credit	Part du crédit alloué effectivement consommée
fait_activites	Total_Activites	Nombre d'activités associatives organisées
fait_activites	Budget_Total_Activites	Budget total alloué aux activités
fait_activites	Budget_Consomme_Activites	Budget effectivement consommé
fait_activites	Total_Participants	Nombre cumulé de participants aux activités
fait_activites	Satisfaction_Moyenne	Taux de satisfaction moyen des activités
fait_activites	Duree_Moyenne_Jours	Durée moyenne des activités
fait_motatawi3	Total_Volontaires	Nombre d'inscriptions au programme de volontariat
dim_beneficiaire	Nb_Beneficiaires_Membres_Associations	Nombre de bénéficiaires PassJeunes également membres d'une association
dim_beneficiaire	Taux_Engagement_Associatif	Part des bénéficiaires PassJeunes membres d'une association

L'écriture de ces mesures a systématiquement privilégié la fonction DIVIDE() plutôt que l'opérateur de division standard, afin de neutraliser proprement les cas de division par zéro (par exemple lorsqu'un filtre appliqué dans Power BI conduit à un dénominateur nul), ce qui évite l'affichage d'erreurs à l'écran et sécurise l'expérience utilisateur du tableau de bord. À titre d'illustration, le code DAX réel de cinq mesures représentatives est reproduit ci-dessous :

```
Nb_Beneficiaires_Actifs =
DISTINCTCOUNT(fait_operations[beneficiaire_id])

Montant_Moyen_Reduction =
AVERAGE(fait_operations[montant_reduction])

Taux_Utilisation_Credit =
DIVIDE(
    SUM(fait_solde[credit_initial]) - SUM(fait_solde[credit_restant]),
```

```

SUM(fait_solde[credit_initial]), 0
)

Satisfaction_Moyenne =
AVERAGE(fait_activites[taux_satisfaction])

Taux_Engagement_Associatif =
DIVIDE(
    CALCULATE(
        COUNTROWS(dim_beneficiaire),
        dim_beneficiaire[est_membre_association] = TRUE()
    ),
    COUNTROWS(dim_beneficiaire), 0
)

```

9.4. Analyse critique et axes de fiabilisation identifiés

Une relecture approfondie du modèle DAX, réalisée en fin de projet, a permis d'identifier plusieurs points à consolider avant une mise en production élargie :

- Les deux mesures portées par dim_beneficiaire (Nb_Beneficiaires_Membres_Associations et Taux_Engagement_Associatif) sont calculées directement sur la table de dimension, sans passer par une table de faits. Or, dans un schéma en étoile à relations à sens unique, un filtre appliqué sur une autre dimension (par exemple la région, via un segment sur dim_region) ne se propage pas automatiquement jusqu'à dim_beneficiaire, car aucune relation directe ne les relie. Ces deux mesures ne réagissent donc, en l'état, qu'aux filtres portant directement sur les attributs de dim_beneficiaire (genre, tranche d'âge, statut), et restent invariantes face à un filtre régional ou temporel appliqué via les tables de faits. Ce comportement, correct techniquement mais potentiellement contre-intuitif pour un utilisateur métier, doit être documenté ou corrigé en reliant cet indicateur à une table de faits pertinente.
- La relation entre dim_beneficiaire (date d'inscription) et dim_temps a été volontairement laissée inactive par défaut dans le modèle — un bon réflexe de conception, puisqu'une relation active aurait fait cohabiter deux notions différentes de « date » (date d'inscription vs date d'opération) sur la même hiérarchie Calendrier, au risque de résultats trompeurs pour l'utilisateur final selon le visuel utilisé. Cette prudence a toutefois un coût : aucune mesure du modèle n'exploite aujourd'hui cette relation, alors qu'elle permettrait des indicateurs utiles au pilotage (par exemple, un suivi du nombre de nouvelles inscriptions par mois). Une évolution recommandée consiste à ajouter une mesure dédiée activant explicitement cette relation via la fonction USERELATIONSHIP, avec un nom sans ambiguïté (par exemple Nb_Nouvelles_Inscriptions), plutôt que de laisser la relation inexploitée.
- La mesure Satisfaction_Moyenne, actuellement une moyenne simple (AVERAGE) du taux de satisfaction par activité, donne un poids identique à une activité rassemblant 5 participants et à une activité en rassemblant 500. Une version pondérée par le nombre de participants (calculée par SUMX du produit taux × participants, rapporté à la somme des participants) donnerait une image plus fidèle de la satisfaction perçue à l'échelle du programme dans son ensemble.

10. Le tableau de bord Power BI

Le tableau de bord final (MJCC_Dashboard.pbix) constitue le point de restitution du projet auprès des utilisateurs métier du Ministère. Il repose sur un modèle composite : une connexion live vers le cube

SSAS_MJCC pour l'ensemble des indicateurs de gestion, complétée par les scores issus des modèles de Machine Learning, réintégrés au Data Warehouse puis au cube selon le pipeline décrit en section 11. Ce choix garantit que le tableau de bord reste toujours cohérent avec le modèle sémantique central, sans duplication manuelle de données. Il est structuré en six pages, chacune correspondant à un axe d'analyse métier distinct. Les captures d'écran présentées ci-dessous sont issues du tableau de bord réellement déployé, données synthétiques de test à l'appui (voir section 3.4).

10.1. Synthèse Exécutive

Page d'accueil destinée aux directeurs, elle affiche en un coup d'œil 8 425 bénéficiaires actifs, 73 263 opérations et 1,58 million de dirhams de réductions accordées sur la période couverte. Le graphique par zone géographique fait apparaître Rabat, Marrakech et Fès comme les trois villes concentrant le plus grand volume de réductions, et le profil des bénéficiaires est très majoritairement marocain (82,76 %), le solde se répartissant entre expatriés, immigrants étrangers et bénéficiaires subsahariens. Trois segments interactifs (année, région, genre) permettent un filtrage transverse de la page.




Figure 13 — Page « Synthèse Exécutive » du tableau de bord MJCC_Dashboard.pbix.

10.2. Analyse des Opérations et Offres

Page dédiée à l'analyse fine de l'usage du dispositif PassJeunes : une réduction moyenne de 21,56 DH, un taux d'utilisation du crédit de 0,50 (soit la moitié du crédit annuel alloué effectivement consommée) et 114 offres actives. Le classement des offres les plus sollicitées est dominé par les offres de santé de proximité (Espace Santé Jeunes à Khouribga et à Kénitra) et les grands sites culturels et de transport (Jardin Zoologique de Rabat, abonnement TRAMWAY). La structure des avantages consommés se répartit entre tarif fixe (40,63 %), gratuité totale (35,85 %) et réduction partielle (23,52 %).




Figure 14 — Page « Analyse des Opérations & Offres ».

10.3. Volontariat Motatawi3

Page consacrée au programme de volontariat : 2 295 volontaires inscrits, répartis sur 12 régions et 11 domaines d'activité. Le développement personnel, l'environnement et le patrimoine figurent parmi les domaines les plus mobilisés, tous niveaux d'études confondus, avec une forte proportion de volontaires de niveau Licence.




Figure 15 — Page « Volontariat Motatawi3 ».

10.4. Vie Associative et Maisons de Jeunes

Page consacrée au suivi du tissu associatif : 1 240 activités organisées, 42 617 participants cumulés, et 577 bénéficiaires PassJeunes identifiés comme engagés en association — la traduction concrète, en un seul

indicateur, de la problématique de transversalité qui a motivé l'ensemble du projet. Le budget consommé s'élève à 3,44 millions de DH. La comparaison entre budget alloué et budget consommé par type d'activité fait apparaître un écart notable : pour les activités régulières comme pour les campus saisonniers, le taux de consommation réel du budget alloué avoisine 45 %, ce qui constitue un signal opérationnel à approfondir avec les équipes de terrain (sous-consommation chronique, ou plutôt sur-allocation budgétaire par anticipation ?). La répartition des activités par type d'association est dominée par les ONG (17,98 %) et les associations culturelles (16,05 %).




Figure 16 — Page « Vie Associative & Maisons de Jeunes ».

10.5. Démographie et Inclusion

Page transversale portant sur le profil sociodémographique des 10 000 bénéficiaires du dispositif, parmi lesquels 335 sont en situation de handicap. La parité hommes/femmes se maintient autour de 50/50 sur l'ensemble des tranches d'âge. La carte de répartition géographique nationale, fondée sur les données Bing Maps de Power BI, confirme une concentration des bénéficiaires sur l'axe Rabat-Casablanca-Marrakech-Fès, avec une présence plus diffuse dans le Nord (Tanger, Nador, Oujda) et le Sud.




Figure 17 — Page « Démographie & Inclusion ».

10.6. Intelligence Artificielle et Machine Learning

Dernière page du tableau de bord, elle affiche un taux de churn global prédit de 42,0 % et identifie 3 000 bénéficiaires à risque élevé (probabilité de désengagement supérieure à 60 %). La répartition par niveau de risque distingue trois bandes : risque faible (39,95 %), moyen (25,65 %) et élevé (34,4 %) — une segmentation en trois classes plus actionnables pour les équipes de terrain qu'une simple probabilité continue. La segmentation comportementale confirme les résultats obtenus en section 11.2 (Régulier 46,15 %, Super-Actif 37,79 %, Occasionnel 16,06 %), et le secteur Culture domine très largement les recommandations générées par le moteur de recommandation IA.




Figure 18 — Page « Intelligence Artificielle & Machine Learning ».

10.7. Synthèse des six pages du tableau de bord

Page	Public cible principal	Indicateurs clés restitués
Synthèse Exécutive	Directeurs / décideurs	8 425 bénéficiaires actifs, 73 263 opérations, 1,58 M DH de réductions
Opérations & Offres	Responsables du dispositif PassJeunes	21,56 DH de réduction moyenne, taux d'utilisation du crédit 0,50, 114 offres actives
Volontariat Motatawi3	Équipe programme volontariat	2 295 volontaires, 12 régions, 11 domaines d'activité
Vie Associative & Maisons	Équipe vie associative / Jam3iya	1 240 activités, 42 617 participants, 577 membres associatifs, 3,44 M DH consommés
Démographie & Inclusion	Analystes / observatoire jeunesse	10 000 bénéficiaires, 335 en situation de handicap, parité ≈ 50/50
Intelligence Artificielle & ML	Directeurs / équipes d'action ciblée	Churn prédit 42,0 %, 3 000 bénéficiaires à risque élevé, 3 segments comportementaux

11. Volet Data Science : les modèles de Machine Learning

Au-delà du reporting descriptif, le stage a permis de développer un volet prédictif à part entière, avec quatre modèles distincts, chacun répondant à un besoin métier précis exprimé par les équipes du Ministère. Un point d'architecture central caractérise ce volet : les quatre modèles suivent un même pipeline fermé (« closed-loop ») — extraction des données depuis le Data Warehouse, entraînement, scoring de l'ensemble de la population, puis écriture des scores directement dans DWH_MJCC (nouvelles colonnes de dim_beneficiaire), suivie d'une mise à jour automatisée du modèle SSAS (ajout de colonnes et de mesures, puis traitement complet du cube via un script PowerShell s'appuyant sur la bibliothèque Microsoft.AnalysisServices.Tabular). Les scores sont ainsi disponibles nativement dans Power BI au même titre que n'importe quel autre indicateur de gestion, sans import manuel ni rupture de cohérence entre les couches du projet.

11.1. Modèle de prédiction du désengagement (Churn)

Objectif : identifier, parmi les bénéficiaires actifs, ceux présentant un risque élevé de cesser d'utiliser le dispositif PassJeunes, afin de permettre une action de relance ciblée. Méthodologie : sur une date de référence (cutoff) fixée au 30 juin 2024, 4 275 bénéficiaires sur 10 000 (42,8 %) ont été qualifiés de « churnés » selon une règle métier d'inactivité prolongée. Un travail de feature engineering avancé a été mené (construction de variables de type RFM — récence, fréquence, montant —, tendances comportementales, variables d'interaction), portant le nombre de variables explicatives à 38. Face au déséquilibre des classes, la technique de sur-échantillonnage SMOTE a été appliquée sur l'ensemble d'entraînement, combinée à un encodage One-Hot et une standardisation des variables numériques.

Cinq modèles ont été comparés (Régression Logistique, Random Forest, Gradient Boosting, XGBoost, et un modèle d'ensemble par Stacking). Le modèle d'ensemble (Stacking) a obtenu les meilleures performances globales, avec un F1-score de 0,6225 et une aire sous la courbe ROC (AUC) de 0,7691, validées par une

validation croisée à 5 plis (F1 moyen de $0,5532 \pm 0,0208$). Sur l'échantillon de test, le modèle atteint une précision de 0,72 et un rappel de 0,74 pour la classe « Actif », et une précision de 0,64 et un rappel de 0,61 pour la classe « Churné », pour une exactitude globale de 0,68.

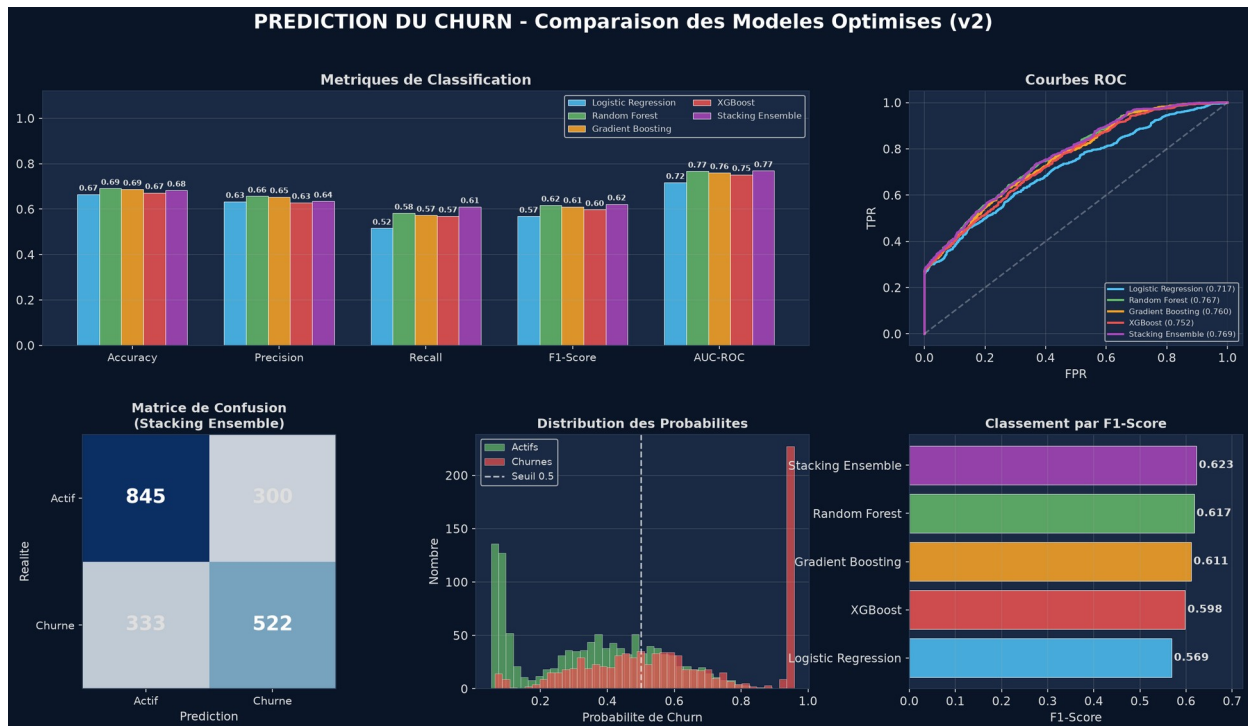


Figure 19 — Comparaison des cinq modèles de prédiction du churn : métriques de classification, courbes ROC, matrice de confusion du modèle retenu (Stacking Ensemble) et classement par F1-score.

L'analyse des variables les plus déterminantes du modèle confirme la pertinence du feature engineering réalisé : l'ancienneté d'inscription (`anciennete_jours`) et le statut de désactivation du Pass (`statut_pass_Desactive`) dominent très largement l'importance des variables, suivies par la fréquence mensuelle d'usage et la récence de la dernière opération — cohérent avec une approche de type RFM.




Figure 20 — Importance des 20 variables les plus déterminantes du modèle (base Random Forest du Stacking Ensemble).

La lecture du churn par tranche d'âge fait apparaître un résultat particulièrement cohérent avec la règle de gestion identifiée en section 3.5 : le taux de churn atteint 64,1 % chez les bénéficiaires de plus de 30 ans, contre 21,8 % à 35,7 % pour les tranches plus jeunes. Ce résultat n'est pas fortuit : il traduit directement la règle de désactivation automatique du PassJeunes à 30 ans, ce qui constitue une validation croisée rassurante entre le modèle prédictif et les règles de gestion réelles du système source. Le taux de churn ne présente en revanche aucun écart significatif selon le genre (42,8 % pour les hommes contre 42,7 % pour les femmes), signal rassurant quant à l'absence de biais démographique du modèle sur cette variable.




Figure 21 — Taux de churn par tranche d'âge et par genre.

11.2. Segmentation comportementale des bénéficiaires

Objectif : regrouper les bénéficiaires en profils homogènes d'usage, afin de personnaliser la communication et l'offre de services du Ministère. Méthodologie : un algorithme K-Means (K=3), appliqué sur 16 variables comportementales, a permis d'identifier trois segments : « Super-Actif » (3 779 bénéficiaires, 37,8 %), « Régulier » (4 615 bénéficiaires, 46,2 %) et « Occasionnel » (1 606 bénéficiaires, 16,1 %). Le score de silhouette obtenu (0,296) indique une séparation modérée mais exploitable entre les groupes, cohérente avec la nature continue (et non naturellement clusterisée) des comportements d'usage d'un dispositif d'avantages. Le choix de K=3 a été validé par la méthode du coude (Elbow) combinée au score de silhouette, ce dernier atteignant son maximum local précisément à K=3.




Figure 22 — Tableau de bord de segmentation K-Means : répartition des segments, validation du nombre de clusters (Elbow/Silhouette), profil radar et comparaison fréquence/montant par segment.

11.3. Moteur de recommandation d'offres

Objectif : suggérer à chaque bénéficiaire les offres les plus susceptibles de l'intéresser, à partir de son historique et de profils similaires. Méthodologie : approche hybride combinant un filtrage collaboratif (similarité cosinus entre profils d'usage) et un mécanisme de repli basé sur le contenu (content-based) pour les bénéficiaires disposant d'un historique insuffisant. L'ensemble des 10 000 bénéficiaires a été scoré sur un catalogue de 114 offres actives. Les secteurs les plus recommandés sont la Culture (64,5 % des recommandations), la Santé (18,3 %), l'Academy — formation (5,2 %), la Banque (3,4 %) et le Loisir (3,1 %), une répartition cohérente avec la structure du catalogue de partenaires disponible.

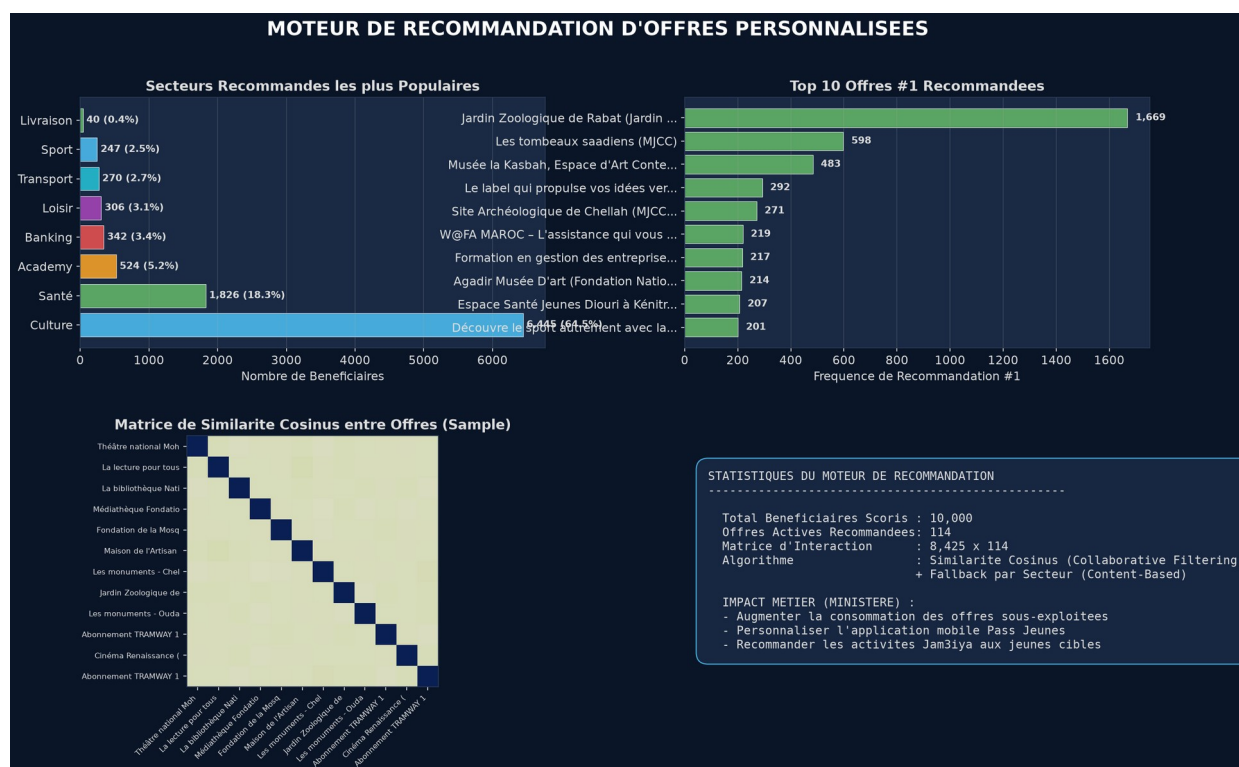


Figure 23 — Tableau de bord du moteur de recommandation : secteurs les plus recommandés, top 10 des offres, matrice de similarité cosinus entre offres et statistiques globales du moteur.

11.4. Modèle de propension à l'engagement associatif

Objectif : ce modèle répond directement à la problématique transverse à l'origine du projet, en identifiant, parmi les bénéficiaires PassJeunes qui ne sont pas encore membres d'une association, ceux présentant la plus forte propension à le devenir, sur la base de leur comportement d'usage du dispositif (fréquence, secteurs sollicités, ancienneté d'inscription). Une comparaison de plusieurs modèles supervisés (Régression Logistique, Random Forest, Gradient Boosting, XGBoost) a été menée, et les scores obtenus sont réintégrés dans le Data Warehouse sous forme de deux nouveaux attributs de dim_beneficiaire (propension_associative et son niveau qualitatif associé), rendant cet indicateur directement exploitable dans le pilotage des actions de médiation associative du Ministère.

12. Résultats, apports pour le Ministère et limites du projet

12.1. Apports concrets pour le pilotage institutionnel

Ce projet apporte au Ministère un outil qui n'existait pas auparavant : une vision consolidée et transverse de l'impact réel des programmes jeunesse, actualisable de façon industrialisée plutôt que par des extractions manuelles ponctuelles. La page « Vie Associative » du tableau de bord, en particulier, permet pour la première fois de répondre directement à la question qui a motivé le projet : mesurer combien de bénéficiaires PassJeunes s'engagent également dans la vie associative locale. Le volet prédictif ajoute une dimension d'anticipation : le Ministère dispose désormais d'une liste priorisée de bénéficiaires à risque de désengagement et d'une liste de bénéficiaires à fort potentiel d'engagement associatif, deux leviers d'action directement mobilisables par les équipes de terrain.

12.2. Limites techniques identifiées

Une lecture critique honnête du projet, nécessaire à sa fiabilisation future, fait ressortir plusieurs limites, déjà détaillées dans les sections correspondantes et rappelées ici de façon synthétique :

- Absence de mécanismes d'intelligence temporelle (comparaisons d'une année sur l'autre, cumuls) dans le modèle DAX actuel, alors que la dimension temporelle du modèle couvre neuf années.
- Typage en chaîne de caractères de certaines colonnes de dates dans `dim_beneficiaire`, limitant l'exploitation native de ces fonctionnalités.
- Deux mesures DAX (liées à l'engagement associatif) calculées sur la table de dimension bénéficiaire, dont le comportement de filtrage croisé avec les autres dimensions (région, temps) doit être mieux documenté auprès des utilisateurs finaux.
- Redondance de référence temporelle sur la table de faits `fait_solde` (attribut `annee` et clé étrangère vers une date complète), à clarifier.
- Absence, à ce stade, de sécurité au niveau des lignes (Row-Level Security), qui serait pourtant pertinente pour un déploiement élargi du tableau de bord permettant à chaque directeur régional de ne visualiser que les données de sa propre région.
- Le chargement incrémental des tables de faits, permettant de ne traiter que les nouvelles données à chaque exécution plutôt qu'un rechargement complet, n'est pas encore finalisé dans les packages SSIS.

Aucune de ces limites ne remet en cause la validité globale de l'architecture ni la fiabilité des indicateurs actuellement restitués ; elles constituent en revanche une feuille de route claire pour la suite du projet, détaillée ci-après.

12.3. Perspectives d'évolution

- Finalisation du chargement incrémental afin de permettre un rafraîchissement quotidien ou hebdomadaire automatisé du Data Warehouse, sans purge complète.
- Correction du typage des colonnes de dates et ajout de mesures d'intelligence temporelle (évolution annuelle, cumuls) pour enrichir la page Synthèse Exécutive.
- Mise en place de la sécurité au niveau des lignes pour permettre un déploiement du tableau de bord directement auprès des directions régionales.
- Ajout d'un axe d'analyse au niveau du partenaire (nombre de partenaires actifs, classement par montant de réduction généré), actuellement disponible dans les données mais non exploité en tant qu'indicateur dédié.
- Automatisation complète du rafraîchissement des quatre modèles de Machine Learning selon une fréquence régulière (par exemple mensuelle), afin que les scores restent représentatifs de l'évolution réelle des comportements.

Afin de faciliter le passage de relais à une équipe de maintenance, ces axes d'évolution sont priorisés ci-dessous selon leur effort de mise en œuvre estimé et leur impact attendu pour les utilisateurs métier du tableau de bord :

Priorité	Action	Effort estimé
Haute	Correction du typage des colonnes de dates de dim_beneficiaire (string → date)	Faible
Haute	Clarification / correction de la double référence temporelle sur fait_solde	Faible
Moyenne	Ajout de mesures d'intelligence temporelle (évolution annuelle, cumuls)	Moyen
Moyenne	Correction du comportement de filtrage croisé des mesures d'engagement associatif	Moyen
Moyenne	Finalisation du chargement incrémental des packages SSIS	Élevé
Basse	Mise en place de la sécurité au niveau des lignes (RLS) par région	Élevé
Basse	Ajout d'un axe d'analyse dédié au niveau du partenaire	Moyen

13. Conclusion générale

Ce stage au sein du Ministère de la Jeunesse, de la Culture et de la Communication a permis de concevoir et de mettre en œuvre, de bout en bout, une infrastructure décisionnelle complète répondant à un besoin institutionnel concret : offrir une vision transverse et actionnable de l'impact des programmes jeunesse, jusque-là cloisonnés dans des systèmes d'information distincts. Le projet a couvert l'ensemble de la chaîne de valeur de la donnée, depuis l'extraction et la modélisation transactionnelle jusqu'à la restitution décisionnelle, en passant par la construction d'un entrepôt de données en schéma en étoile, d'un modèle sémantique analytique en DAX, et d'un tableau de bord Power BI structuré en six axes métier.

Il a également été l'occasion d'aller au-delà du reporting descriptif classique, en intégrant un véritable volet de Data Science : quatre modèles de Machine Learning, couvrant la prédiction du désengagement, la segmentation comportementale, la recommandation d'offres et la propension à l'engagement associatif, intégrés selon un pipeline automatisé et fermé jusqu'au tableau de bord final. Cette dimension prédictive constitue, à mon sens, l'apport le plus différenciant du projet : elle transforme un outil de constat en un outil d'anticipation, directement mobilisable par les équipes du Ministère pour orienter leurs actions de terrain.

Sur le plan personnel, ce stage a représenté une mise en pratique concrète et exigeante de l'ensemble de la chaîne d'un projet Business Intelligence en environnement professionnel réel : conception d'architecture, développement ETL, modélisation dimensionnelle, écriture de mesures analytiques, restitution visuelle et intégration de modèles prédictifs. La démarche d'analyse critique menée en fin de projet, qui a permis d'identifier précisément les limites actuelles du modèle et de tracer une feuille de route d'amélioration réaliste, constitue à elle seule un exercice professionnel à part entière, essentiel à la maturité de tout projet décisionnel appelé à évoluer dans la durée.

Annexe A — Extrait de code SQL : génération de la dimension temporelle

L'extrait suivant illustre la génération automatisée de la dimension dim_temps par requête récursive T-SQL (CTE), couvrant la période 2018-2026 sans nécessiter de saisie manuelle ni d'outil externe.

```
CREATE TABLE dbo.dim_temps (
    temps_id          INT          PRIMARY KEY,    -- format YYYYMMDD
    date_complete     DATE        NOT NULL UNIQUE,
    jour              TINYINT     NOT NULL,
    mois              TINYINT     NOT NULL,
    annee             SMALLINT    NOT NULL,
    trimestre         TINYINT     NOT NULL,
    nom_jour          NVARCHAR(10) NOT NULL,
    nom_mois          NVARCHAR(10) NOT NULL,
    jour_semaine      TINYINT     NOT NULL,
    semaine_annee     TINYINT     NOT NULL,
    est_weekend       BIT         NOT NULL DEFAULT 0
);

-- Remplissage automatique de dim_temps (2018-2026)
WITH Dates AS (
    SELECT CAST('2018-01-01' AS DATE) AS d
    UNION ALL
    SELECT DATEADD(DAY, 1, d)
    FROM Dates
    WHERE d <= '2026-12-31'
)
INSERT INTO dbo.dim_temps (
    temps_id, date_complete, jour, mois, annee, trimestre,
    nom_jour, nom_mois, jour_semaine, semaine_annee, est_weekend
)
SELECT
    CONVERT(INT, FORMAT(d, 'yyyyMMdd')), d, DAY(d), MONTH(d), YEAR(d),
    DATEPART(QUARTER, d),
    CASE DATEPART(WEEKDAY, d)
        WHEN 1 THEN 'Dimanche' WHEN 2 THEN 'Lundi' WHEN 3 THEN 'Mardi'
        WHEN 4 THEN 'Mercredi' WHEN 5 THEN 'Jeudi' WHEN 6 THEN 'Vendredi'
        WHEN 7 THEN 'Samedi' END,
    CASE MONTH(d)
        WHEN 1 THEN 'Janvier' WHEN 2 THEN 'Février' WHEN 3 THEN 'Mars'
        -- (suite des 12 mois, omise ici par souci de concision)
    END,
    DATEPART(WEEKDAY, d), DATEPART(ISO_WEEK, d),
    CASE WHEN DATEPART(WEEKDAY, d) IN (1,7) THEN 1 ELSE 0 END
FROM Dates
OPTION (MAXRECURSION 0);
```

Cette approche déclarative, exécutée en une seule instruction grâce à l'option MAXRECURSION 0 (levée de la limite par défaut de 100 récursions de SQL Server), a été préférée à une boucle procédurale pour sa lisibilité et sa performance.

Annexe B — Glossaire et liste des abréviations

Terme	Définition
BI	Business Intelligence — informatique décisionnelle
DWH	Data Warehouse — entrepôt de données
ETL	Extract-Transform-Load — extraction, transformation et chargement des données
OLTP	OnLine Transaction Processing — système transactionnel de production
SSIS	SQL Server Integration Services — outil d'orchestration ETL de Microsoft
SSAS Tabular	SQL Server Analysis Services (mode Tabular) — moteur de modèle sémantique en mémoire
DAX	Data Analysis Expressions — langage de formules utilisé par SSAS Tabular et Power BI
VertiPaq	Moteur de stockage colonnaire en mémoire utilisé par SSAS Tabular et Power BI
Schéma en étoile	Modélisation dimensionnelle organisant les données en tables de faits (mesures) reliées à des tables de dimensions (axes d'analyse)
Grain	Niveau de détail représenté par une ligne d'une table de faits
RFM	Récence, Fréquence, Montant — famille de variables classiquement utilisées en analyse comportementale client
SMOTE	Synthetic Minority Over-sampling Technique — technique de rééquilibrage des classes en apprentissage supervisé
K-Means	Algorithme de partitionnement non supervisé (clustering) basé sur la minimisation de la distance aux centroïdes
F1-score	Moyenne harmonique de la précision et du rappel, utilisée pour évaluer un modèle de classification, en particulier sur des classes déséquilibrées
AUC-ROC	Aire sous la courbe ROC — mesure de la capacité globale d'un modèle de classification à discriminer les classes
RLS	Row-Level Security — mécanisme de sécurité restreignant les lignes de données visibles selon l'identité de l'utilisateur connecté
CIN	Carte d'Identité Nationale — identifiant utilisé pour le rapprochement des individus entre PassJeunes et Jam3iya.ma

Annexe C — Environnement technique

Le tableau ci-dessous recense les principaux outils et bibliothèques mobilisés pour la réalisation du projet, à titre de référence pour toute reprise ou maintenance ultérieure.

Composant	Technologie	Usage dans le projet
SGBD relationnel (sources / DWH)	Microsoft SQL Server	PassJeunesDB, STAGING_MJCC, DWH_MJCC
SGBD relationnel (source)	MySQL	jam3iya_db
Orchestration ETL	SQL Server Integration Services (SSIS)	Projet ETL_MJCC (packages et Master Package)
Modèle sémantique	SQL Server Analysis Services — mode Tabular	SSAS_MJCC, moteur VertiPaq
Langage de calcul analytique	DAX (Data Analysis Expressions)	17 mesures du modèle SSAS
Restitution décisionnelle	Microsoft Power BI Desktop	MJCC_Dashboard.pbix (modèle composite)
Génération des données de test	Python (pandas, numpy, Faker)	Scripts de génération de données synthétiques
Machine Learning	Python (scikit-learn, XGBoost, imbalanced-learn)	Churn, segmentation, recommandation, engagement associatif
Automatisation du déploiement du cube	PowerShell + Microsoft.AnalysisServices.Tabular (AMO/TOM)	Réintégration des scores ML et traitement (Process Full) du cube

L'ensemble des scripts SQL, packages SSIS, du modèle SSAS (Model.bim) et des scripts Python constituant le projet est archivé et versionné, garantissant la reproductibilité de l'ensemble du pipeline décrit dans ce rapport.

Annexe D — Diagrammes entité-relation détaillés des systèmes sources

Les deux diagrammes ci-dessous détaillent, avec la notation crow's foot (cardinalités exactes), la structure entité-relation complète des deux bases sources décrites en section 6, en complément de la vue synthétique de la figure 1.




Figure 24 — Diagramme entité-relation détaillé de PassJeunesDB (SQL Server).




Figure 25 — Diagramme entité-relation détaillé de jam3iya_db (MySQL).